文件：模型测试报告资料包：说明与文件清单
来源：https://ark.volcengine.com/region:cn-beijing/model/leaderboard
下载/转换时间：2026-10-21

本文件为资料包导读，由整理方编写；01-08 号文件为官方页面或第三方页面转换件，内容未改写。

模型测试报告资料包

GLM-5.3-Flash 与 DeepSeek-V4.1-Flash-1017｜2026-10-21 整理

本资料包用于客户沟通与选型参考。所有文件均来自模型厂商官方页面、HuggingFace 官方模型卡或第三方评测站；火山方舟侧目前没有这两款第三方模型的公开能力评测报告，只有性能榜单与模型文档。

一、文件清单

编号	文件	来源	性质	关键内容
01	DeepSeek-V4.1 技术报告	DeepSeek 官方	**原版 PDF**（51 页）	V4.1 架构、训练、Base/Instruct 评测；对应 260910 版本
02	DeepSeek-V4.1-Flash 官方发布页	DeepSeek 官方	网页转 PDF	发布说明、定价、开源信息、与旗舰模型对比表
03	GLM-5.3-Flash 官方技术报告	Z.ai 官方博客	网页转 PDF	完整 Benchmark 表、评测口径脚注、AA 指数与成本
04	GLM-5.3-Flash 模型卡	HuggingFace	网页转 PDF	模型介绍、部署方式、Eval Results、引用信息
05	DeepSeek-V4.1-Flash 模型卡	HuggingFace	网页转 PDF	Base/Instruct 评测表、评测设置、复现说明
06	DeepSeek API 更新日志	DeepSeek 官方	网页转 PDF	**1017 版本官方分数**；1017 无单独 PDF 报告
07	第三方对比 BenchLM	BenchLM	网页转 PDF	1017 vs GLM-5.3-Flash，含 CSV/JSON 下载入口
08	第三方对比 Artificial Analysis	AA	网页转 PDF	Intelligence Index、分项分数、价格；版本需核对

二、先说结论

1. **火山方舟官网没有这两款模型的“能力测试报告”可下载。** 官网客服给的 模型性能榜单 是统一拨测下的延迟/吞吐榜单，不含 Benchmark 能力分数；模型详情页只有价格、能力项、上下文与限流。
2. **能力数据的一手来源是模型厂商**：GLM-5.3-Flash 看 Z.ai 技术博客与 HuggingFace 模型卡；DeepSeek 看官方技术报告 PDF、模型卡和更新日志。
3. **DeepSeek-V4.1-Flash-1017 没有单独的技术报告 PDF。** 51 页的 V4.1 技术报告对应 260910 版本；1017 的官方分数只发布在更新日志里（见 06 号文件）。
4. **第三方数据版本不一致**：BenchLM 页面明确标注 1017（2026-10-20 更新）；Artificial Analysis 对比页仍显示“DeepSeek V4.1 Flash (Max)” 为 39，疑似未更新到 1017。引用第三方分数前必须核对版本与口径。

三、官方口径的关键分数

GLM-5.3-Flash（Z.ai 官方博客）

Benchmark	GLM-5.3-Flash	GLM-5.2
Terminal Bench 2.1	84.3	81.0
DeepSWE v1.1	63.4	46.2
NL2Repo	56.3	48.9
Toolathlon Verified	78.4	59.9

Benchmark	GLM-5.3-Flash	GLM-5.2
AutomationBench v1.0.6	48.8	26.2
Agents' Last Exam	26.3	20.4
HLE w/ Tools	55.3	54.7
OfficeQA Pro	62.4	—

官方博客同时给出 Artificial Analysis Intelligence Index **57**、单任务成本约 **$0.045**（discounted）。

DeepSeek-V4.1-Flash-1017（DeepSeek 官方更新日志）

Benchmark	1017 结果
HLE (w/o tools)	42.6（44.0，纯文本子集）
Terminal-Bench 4.0	42.3
DeepSWE v1.1	77.0
ProgramBench	29.1
NL2Repo-Bench	68.2
Automation-Bench v1.0.6	60.5
Agents' Last Exam	35.4
Apex Bench v1.1	72.1
Chartography (w/tools)	83.0
BabyVision (w/tools)	92.5
ZeroBench-main (w/tools)	51.0

注：Terminal-Bench 4.0 使用 Claude Code 框架，DeepSWE 使用 Mini-SWE-V2 框架，ZeroBench 使用 Pass@5。厂商之间的 harness、子集、采样参数不同，**不要把这些分数直接拼成一张对比表**。

四、建议怎么给客户

- **首选组合**：01/03 厂商官方报告（证明能力上限）+ 04/05 模型卡（证明可复现与开源许可）+ 02/06 官方版本与定价说明。
- **补充火山侧材料**：方舟模型详情页截图（证明在火山上的能力项、上下文、限流与价格）+ 模型性能榜单截图（证明延迟/吞吐）。这两项是火山官网真实存在、可公开引用的内容。
- **如果客户要“在你们场景里的测试报告”**：给客户开子账号，在方舟「模型评测」里用客户业务数据跑任务，任务详情支持查看、下载评测得分与部分样本数据，并支持多任务对比。这是火山侧唯一能产出“报告”的路径。
- **如果客户坚持要“火山官方盖章的能力报告”**：明确告知公开渠道没有；只能走内部申请或客户自测，内部报告不对外承诺。

可直接回复客户：

> 火山方舟对第三方模型目前只公开性能榜单（延迟/吞吐），不单独发布能力评测报告。能力数据以模型厂商官方技术报告和模型卡为准，我们已整理成 PDF：GLM-5.3-Flash 的官方技术博客与模型卡、DeepSeek-V4.1-Flash 的官方技术报告与 1017 更新日志。另外可以用你们的真实数据在方舟上跑一份可导出的评测报告，对你们场景的参考价值更高。

五、版本与引用注意

- 方舟 Model ID：`glm-5-3-flash-260828`、`deepseek-v4-1-flash-261017`；DeepSeek 另有旧版 `deepseek-v4-1-flash-260910`，注意别测错。

- GLM-5.3-Flash：2026-08-26 发布，MIT 许可，权重开源；官方“技术报告”是博客页面，没有官方 PDF，本包为网页转 PDF。
- DeepSeek-V4.1-Flash：技术报告 PDF 为 2026-09-10 发布版本；1017 为 2026-10-17 增量更新。
- 第三方页面（07/08）受其服务条款约束，对外转发前请确认许可；本包仅作内部沟通与客户参考。
- 本包中的网页转 PDF 保留原文与表格，但可能丢失交互元素；关键数字请以原始链接为准。

六、原始链接

- 火山方舟模型性能榜单：https://ark.volcengine.com/region:cn-beijing/model/leaderboard
- 火山方舟 GLM-5.3-Flash：https://ark.volcengine.com/region:cn-beijing/model/detail?name=glm-5-3-flash
- 火山方舟 DeepSeek-V4.1-Flash：https://ark.volcengine.com/region:cn-beijing/model/detail?name=deepseek-v4-1-flash
- 方舟模型评测文档：https://www.volcengine.com/docs/82379/1150782
- GLM-5.3-Flash 官方博客：https://z.ai/blog/glm-5.3-flash
- GLM-5.3-Flash 模型卡：https://huggingface.co/zai-org/GLM-5.3-Flash
- DeepSeek 官方发布页：https://api-docs.deepseek.com/news/news260910/
- DeepSeek 更新日志：https://api-docs.deepseek.com/zh-cn/updates/
- DeepSeek 技术报告 PDF：https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash/blob/main/DeepSeek_V41_Tech_Report.pdf
- BenchLM 对比：https://benchlm.ai/compare/deepseek-v4-1-flash-vs-glm-5-3-flash
- Artificial Analysis 对比：https://artificialanalysis.ai/models/comparisons/deepseek-v4-1-flash-vs-glm-5-3-flash